

Steam Game Success Analyzer: Prediksi Kesuksesan dan Segmentasi Pasar Game Steam

Daniel Evan Rusli¹, Azzahra Anggarista Yoan Putri², Maria Elvaretta Cempaka Ayu S.³

^{1,2} Program Studi Sistem Informasi, Universitas Negeri Surabaya

24051214009@mhs.unesa.ac.id | 24051214032@mhs.unesa.ac.id | 24051214033@mhs.unesa.ac.id

Abstrak—Industri game digital mengalami pertumbuhan yang sangat pesat, khususnya pada platform *Steam* yang menampung lebih dari puluhan ribu judul game dari berbagai pengembang di seluruh dunia. Tingginya jumlah game yang dirilis setiap tahun menyebabkan persaingan yang semakin ketat sehingga hanya sebagian kecil game yang mampu mencapai tingkat kesuksesan yang signifikan. Penelitian ini bertujuan untuk membangun sistem analisis berbasis *data mining* yang mampu memprediksi potensi kesuksesan game serta melakukan segmentasi pasar berdasarkan karakteristik performa game di *Steam*. Dataset yang digunakan berasal dari *Steam Games Dataset* dengan total 124.146 data game dan 41 atribut. Framework yang digunakan adalah *CRISP-DM* yang mencakup tahapan *Business Understanding*, *Data Understanding*, *Data Preparation*, *Modeling*, *Evaluation*, dan *Deployment*. Metode klasifikasi yang digunakan adalah *Gradient Boosting*, *Random Forest*, dan *Logistic Regression*, sedangkan segmentasi pasar dilakukan menggunakan *K-Means Clustering*. Untuk mengatasi ketidakseimbangan kelas digunakan teknik *SMOTE*. Hasil penelitian menunjukkan bahwa *Gradient Boosting* memberikan performa terbaik dengan nilai *AUC-ROC* sebesar 0,8732. Pada proses *clustering* diperoleh empat segmen pasar utama berdasarkan hasil *Elbow Method* dan *Silhouette Score* dengan nilai optimal $K=4$. Model terbaik kemudian diimplementasikan ke dalam aplikasi web berbasis *Streamlit* yang berfungsi sebagai *Decision Support System (DSS)* bagi pengembang game indie. Sistem mampu memberikan prediksi tingkat kesuksesan, analisis kompetitif, visualisasi data, serta rekomendasi strategis berbasis data historis *Steam*.

Kata Kunci— *Data Mining*, *Gradient Boosting*, *K-Means Clustering*, *Steam Games*, *Decision Support System*.

I. PENDAHULUAN

Industri game digital merupakan salah satu sektor industri kreatif dengan pertumbuhan tercepat dalam beberapa dekade terakhir. Platform *Steam* milik Valve Corporation telah menjadi salah satu marketplace game terbesar di dunia, menyediakan akses distribusi digital bagi pengembang game dari berbagai skala — mulai dari studio AAA besar hingga pengembang indie perseorangan. Sejak diperkenalkannya program *Steam Direct*, pengembang indie memiliki akses yang jauh lebih mudah untuk mempublikasikan game mereka ke pasar global hanya dengan membayar biaya pendaftaran sebesar \$100 per judul.

Kemudahan akses ini menciptakan dua sisi mata uang yang berbeda. Di satu sisi, ia membuka peluang yang sangat

besar bagi para pengembang indie untuk menjangkau pasar global tanpa perlu melalui publisher tradisional. Di sisi lain, tingginya volume game baru yang dirilis setiap harinya menciptakan persaingan yang sangat ketat dan fenomena yang dikenal sebagai "noise problem", di mana game-game baru tenggelam dalam lautan pilihan yang tersedia bagi konsumen. Dengan lebih dari 50.000 judul yang tersedia dan ratusan game baru yang dirilis setiap bulan, visibilitas menjadi tantangan utama bagi pengembang indie.

Berdasarkan *Steam Games Dataset* yang digunakan dalam penelitian ini, hanya sekitar 8% dari 124.146 judul game yang berhasil mencapai tingkat kesuksesan yang signifikan (kategori *Successful* ke atas berdasarkan market impact score). Sisanya, sekitar 92%, tergolong dalam kategori *Moderate* atau bahkan *Failure*. Fenomena ini mencerminkan distribusi long-tail yang sangat ekstrem dalam industri game digital, di mana sebagian kecil game mendominasi perhatian, pendapatan, dan engagement pasar secara keseluruhan, sementara mayoritas game tidak berhasil mendapatkan traction yang memadai.

Kondisi inilah yang memotivasi penelitian ini untuk mengembangkan sebuah sistem analisis berbasis data mining yang dapat membantu pengembang game indie membuat keputusan yang lebih terinformasi sebelum meluncurkan produk mereka. Dengan memanfaatkan dataset historis dari 124.146 game *Steam*, penelitian ini mengimplementasikan dua metode data mining utama: *Gradient Boosting Classification* untuk memprediksi tingkat potensi kesuksesan, dan *K-Means Clustering* untuk memetakan posisi kompetitif sebuah game dalam ekosistem pasar *Steam*. Hasil analisis kemudian diintegrasikan ke dalam aplikasi web interaktif berbasis *Streamlit* yang berfungsi sebagai *Decision Support System (DSS)*.

Sistem ini memungkinkan pengguna untuk memasukkan parameter rancangan game mereka dan mendapatkan analisis kompetitif berbasis data historis secara real-time, termasuk skor daya saing (1–10), diagnostik fitur, dan rekomendasi strategis yang disesuaikan dengan genre game. Kontribusi utama penelitian ini adalah: (1) membangun model prediksi kesuksesan game berbasis *Gradient Boosting* dengan *AUC-ROC* optimal; (2) mengidentifikasi empat arketipe pasar game *Steam* melalui *K-Means Clustering*; dan (3) mengimplementasikan model terbaik ke dalam aplikasi web interaktif sebagai *DSS* bagi pengembang game indie.

II. TINJAUAN PUSTAKA

A. Data Mining dan Knowledge Discovery in Databases (KDD)

Data mining merupakan proses komputasional untuk menemukan pola tersembunyi, anomali, dan pengetahuan yang dapat ditindaklanjuti dari dataset berukuran besar menggunakan kombinasi teknik statistik, machine learning, dan manajemen basis data [1]. Referensi [1] memperkenalkan konsep Knowledge Discovery in Databases (KDD) sebagai proses yang lebih luas dan menyeluruh yang mencakup enam langkah sekuensial: Data Mentah → Seleksi → Preprocessing → Transformasi → Mining → Evaluasi → Pengetahuan.

Dalam penelitian ini, pendekatan KDD diterapkan pada 124.146 game Steam untuk mengekstrak dua jenis pengetahuan yang saling melengkapi. Pertama, predictive knowledge berupa model klasifikasi yang mampu memprediksi potensi kesuksesan berdasarkan atribut pre-launch. Kedua, descriptive knowledge berupa struktur segmentasi pasar yang mengungkap arketipe game yang secara alami terbentuk dalam ekosistem Steam. Perbedaan mendasar antara supervised dan unsupervised learning inilah yang memotivasi penggunaan dua metode berbeda secara bersamaan.

Salah satu tantangan terbesar dalam data mining adalah masalah **class imbalance** — kondisi di mana distribusi kelas target sangat tidak seimbang. Dalam dataset penelitian ini, hanya 7,98% game yang masuk kategori sukses. Kondisi ini secara langsung mempengaruhi proses pembelajaran model; jika dibiarkan, algoritma machine learning akan bias ke arah kelas mayoritas karena minimasi fungsi kerugian lebih mudah dicapai dengan selalu memprediksi kelas terbesar. Referensi [2] mengklasifikasikan pendekatan penanganan class imbalance ke dalam empat kategori: under-sampling, over-sampling, kombinasi keduanya, dan ensemble methods.

B. Framework CRISP-DM

Cross-Industry Standard Process for Data Mining (CRISP-DM) dikembangkan oleh konsorsium SPSS, NCR, Daimler-Benz, dan OHRA yang mulai dikonsepsikan pada tahun 1996 dan dipublikasikan secara resmi pada tahun 2000 [3]. Framework ini menjadi standar de facto dalam industri data mining karena sifatnya yang domain-agnostik dan iteratif. Enam fase CRISP-DM saling terhubung dan dapat diulang:

1. Business Understanding — Mendefinisikan tujuan bisnis, menerjemahkannya menjadi masalah data mining, dan menyusun rencana proyek. Ini adalah fase paling kritis karena kesalahan di sini tidak dapat diperbaiki oleh kualitas teknis yang sempurna sekalipun.
2. Data Understanding — Pengumpulan data awal, eksplorasi statistik deskriptif, dan identifikasi masalah kualitas data (missing values, outlier, distribusi tidak merata).
3. Data Preparation — Seleksi fitur, pembersihan data, rekayasa fitur (feature engineering), normalisasi, dan

penanganan class imbalance. Fase ini mengonsumsi sekitar 60–80% dari total waktu proyek.

4. Modeling — Pemilihan teknik machine learning, kalibrasi hyperparameter, dan pelatihan model. Beberapa teknik dapat diuji secara paralel dan dibandingkan.
5. Evaluation — Penilaian model secara menyeluruh terhadap tujuan bisnis, tidak hanya berdasarkan metrik teknis. Model terbaik secara teknis belum tentu yang terbaik dari perspektif bisnis.
6. Deployment — Implementasi model ke dalam sistem produksi yang dapat digunakan oleh pemangku kepentingan secara langsung.

Kekuatan CRISP-DM terletak pada sifatnya yang iteratif dan reflektif. Setiap fase dapat memicu kembali ke fase sebelumnya — misalnya, temuan pada fase Modeling dapat mengarahkan ke fase Data Preparation ulang untuk rekayasa fitur tambahan. Dalam penelitian ini, iterasi terjadi khususnya antara fase Data Preparation dan Modeling selama proses optimasi penanganan class imbalance dengan SMOTE.

C. Gradient Boosting Classification

Gradient Boosting diperkenalkan dalam makalah seminal "Greedy Function Approximation: A Gradient Boosting Machine" [4]. Pendekatan ini memandang masalah estimasi fungsi sebagai optimasi numerik dalam ruang fungsi, bukan ruang parameter. Tujuan utamanya adalah meminimumkan nilai harapan dari suatu fungsi kerugian $L(y, F(x))$ pada distribusi bersama dari semua pasangan (y, x) :

$$F^*(x) = \operatorname{argmin}_F E_{\{y,x\}} [L(y, F(x))] \quad (1)$$

di mana y adalah label aktual dan $F(x)$ adalah fungsi pendekatan yang ingin dioptimalkan. Dari persamaan (2) tersebut, referensi [4] mengembangkan pendekatan stagewise additive expansion yang merupakan kombinasi dari M model lemah (weak learners), yaitu:

$$F(x) = \sum_{m=0}^{M-1} f_m(x) = f_0(x) + \sum_{m=1}^{M-1} f_m(x) \quad (2)$$

di mana $f_0(x)$ adalah tebakan awal (umumnya rata-rata atau log-odds dari kelas mayoritas), dan setiap $f_m(x)$ adalah pohon keputusan dangkal yang dilatih pada iterasi ke- m . Model pada iterasi ke- m diperbarui sebagai:

$$F_m(x) = F_{m-1}(x) + v \cdot \rho_m \cdot h(x; a_m) \quad (3)$$

di mana v ($0 < v \leq 1$) adalah learning rate yang mengontrol kontribusi setiap pohon (dikenal sebagai shrinkage dalam referensi [4]), ρ_m adalah skalar hasil line search, dan $h(x; a_m)$ adalah pohon keputusan ke- m dengan parameter a_m .

Kunci dari Gradient Boosting adalah bahwa setiap pohon baru dilatih untuk memprediksi pseudo-residual — yaitu gradien negatif dari fungsi kerugian terhadap prediksi

model sebelumnya (persamaan ini dikenal sebagai Algorithm 1 dalam referensi [4]):

$$\tilde{r}_{im} = -[\partial L(y_i, F(x_i)) / \partial F(x_i)] \mid_{F=F_{m-1}}, \quad i = 1, \dots, n \quad (4)$$

Untuk masalah klasifikasi biner yang digunakan dalam penelitian ini, referensi [4] merekomendasikan fungsi kerugian negative binomial log-likelihood (LK TreeBoost, Algorithm 5 dalam paper asli), yang untuk kasus dua kelas ($y \in \{-1, +1\}$) dinyatakan sebagai:

$$L(y, F) = \log(1 + \exp(-2yF)) \quad (5)$$

Pseudo-residual untuk loss function ini adalah [4]:

$$\tilde{r}_i = 2y_i / (1 + \exp(2y_i \cdot F_{m-1}(x_i))) \quad (6)$$

Probabilitas prediksi kelas positif diperoleh dari model akhir $F_M(x)$ melalui transformasi logistik:

$$\begin{aligned} P+(x) &= P(y = 1 \mid x) \\ &= 1 / (1 + e^{-2 \cdot F_M(x)}) \end{aligned} \quad (7)$$

Regularisasi dalam Gradient Boosting dilakukan melalui tiga mekanisme: (1) shrinkage melalui learning rate v yang kecil (referensi [4] menunjukkan bahwa $v = 0,1$ memberikan hasil yang jauh lebih baik daripada tanpa shrinkage); (2) pembatasan kedalaman pohon J ($\max_depth$) untuk mengontrol kompleksitas interaksi fitur; dan (3) pembatasan jumlah iterasi M ($n_estimators$). Dalam penelitian ini, parameter yang digunakan adalah $n_estimators = 100$, $learning_rate = 0,1$, $\max_depth = 3$.

Feature importance pada Gradient Boosting dihitung sebagai rata-rata peningkatan squared-error di semua split yang melibatkan fitur tersebut, dijumlahkan di seluruh pohon [4]:

$$I^2_j = (1/M) \sum_{m=1}^M \sum_{t=1}^{J-1} \hat{r}_t^2 \cdot \mathbb{1}[v_t = j] \quad (8)$$

di mana $\hat{r}_t^2$ adalah empirical improvement in squared error pada split node t , dan v_t adalah variabel splitting pada node t . Nilai I_j digunakan untuk mengidentifikasi fitur-fitur yang paling berpengaruh dalam prediksi, yang merupakan salah satu output utama penelitian ini.

D. K-Means Clustering

K-Means oleh referensi [5] adalah algoritma partitioning clustering yang membagi n data point ke dalam K cluster yang saling tidak tumpang tindih dengan meminimumkan Within-Cluster Sum of Squares (WCSS), yang juga disebut inertia J :

$$\begin{aligned} J &= \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2 \end{aligned} \quad (9)$$

di mana C_k adalah himpunan data point dalam cluster ke- k dan μ_k adalah centroid (vektor rata-rata) cluster ke- k .

Algoritma Lloyd bekerja secara iteratif melalui dua langkah yang bergantian sampai konvergen:

Langkah E (Assignment): Setiap data point ditugaskan ke cluster dengan centroid terdekat berdasarkan jarak Euclidean:

$$\begin{aligned} C_k &= \{x_i : \|x_i - \mu_k\|^2 \\ &\leq \|x_i - \mu_j\|^2 \quad \forall j \neq k\} \end{aligned} \quad (10)$$

Langkah M (Update): Centroid diperbarui sebagai rata-rata aritmetika semua data point dalam cluster:

$$\mu_k = (1/|C_k|) \cdot \sum_{x_i \in C_k} x_i \quad (11)$$

Penentuan nilai K optimal menggunakan dua metrik komplementer. Pertama, **Elbow Method**: mengamati penurunan inertia J seiring bertambahnya K . Titik siku (elbow) di mana penurunan mulai melandai menandakan K optimal. Kedua, **Silhouette Score** untuk setiap data point i (Rousseeuw, 1987) didefinisikan sebagai:

$$s(i) = (b(i) - a(i)) / \max\{a(i), b(i)\} \quad (12)$$

di mana $a(i)$ adalah rata-rata jarak i ke semua titik lain dalam cluster yang sama (cohesion), dan $b(i)$ adalah rata-rata jarak minimum i ke titik-titik di cluster terdekat yang berbeda (separation). Nilai $s(i) \in [-1, +1]$: mendekati $+1$ berarti data point berada dengan tepat di dalam cluster-nya; mendekati 0 berarti berada di batas antar cluster; mendekati -1 menandakan kemungkinan salah cluster. Global Silhouette Score adalah rata-rata $s(i)$ atas seluruh data point.

Sebelum clustering, seluruh fitur dinormalisasi menggunakan StandardScaler (Z-score normalization) karena K-Means sensitif terhadap skala fitur:

$$x' = (x - \mu) / \sigma \quad (13)$$

Tanpa normalisasi ini, fitur dengan rentang nilai besar seperti `estimated_owners` (yang dapat mencapai jutaan) akan mendominasi perhitungan jarak Euclidean dan menghasilkan clustering yang bias, mengabaikan fitur-fitur penting berskala kecil seperti `price` atau `positive_ratio`.

E. SMOTE (Synthetic Minority Over-sampling Technique)

SMOTE adalah teknik over-sampling untuk menangani class imbalance yang diimplementasikan dalam library `imbalanced-learn` [6]. Berbeda dengan simple random oversampling yang menduplikasi sampel minoritas secara langsung, SMOTE menghasilkan sampel sintesis baru melalui interpolasi dalam ruang fitur:

$$\begin{aligned} x_{\text{new}} &= x_i + \lambda \cdot (\tilde{x}_{nn} - x_i), \\ \lambda &\in U[0, 1] \end{aligned} \quad (14)$$

di mana x_i adalah sampel kelas minoritas yang dipilih, $\tilde{x}_{nn}$ adalah salah satu dari k nearest neighbor dari x_i dalam kelas yang sama (dipilih secara acak), dan λ adalah skalar acak terdistribusi seragam pada interval $[0, 1]$. Sampel baru x_{new}

terletak di sepanjang segmen garis antara x_i dan $\tilde{x}_{nn}$ sehingga menghasilkan keberagaman yang lebih tinggi dibandingkan duplikasi langsung.

Referensi [2] mendefinisikan rasio keseimbangan dataset χ sebagai:

$$r_\chi = |\chi_{\min}| / |\chi_{\max}| \quad (15)$$

di mana $|\chi_{\min}|$ dan $|\chi_{\max}|$ adalah jumlah sampel kelas minoritas dan mayoritas. Proses balancing menghasilkan dataset baru χ_{res} sedemikian sehingga $r_{\text{res}} \geq r_\chi$. Dalam penelitian ini, SMOTE mengubah rasio dari 7,98% (kelas sukses) menjadi 50% — seimbang sempurna.

Aspek kritis dalam implementasi: SMOTE hanya diterapkan pada **data pelatihan**, tidak pada data test. Penerapan SMOTE pada data test akan menyebabkan data leakage — model akan dievaluasi pada distribusi data yang telah dimodifikasi secara artifisial, bukan distribusi data nyata yang akan ditemui di deployment. Implementasi menggunakan class **SMOTE** dari library `imbalanced-learn` dengan parameter `k_neighbors = 5` (default) [2].

Prosedur SMOTE pada referensi [6]:

INPUT: T (training data), N (oversampling rate %), k (nearest neighbors)

1. Untuk setiap sampel $x_i \in$ kelas minoritas:
2. Hitung k nearest neighbors $x_{nn1}, \dots, x_{nnk}$ dalam kelas yang sama
3. Untuk $r = 1$ to $N/100$:
4. Pilih acak satu tetangga $\tilde{x}_{nn}$ dari $\{x_{nn1}, \dots, x_{nnk}\}$
5. $\lambda \leftarrow \text{random}(0, 1)$
6. $x_{\text{new}} \leftarrow x_i + \lambda \cdot (\tilde{x}_{nn} - x_i)$
7. Tambahkan x_{new} ke dataset sintetis OUTPUT: Dataset yang diperkaya dengan sampel sintetis kelas minoritas

F. Random Forest

Random Forest adalah algoritma ensemble yang membangun sejumlah besar pohon keputusan secara paralel. Referensi [7] mendefinisikan random forest secara formal sebagai:

"A random forest is a classifier consisting of a collection of tree-structured classifiers $\{h(x, \Theta_k), k = 1, \dots\}$ where the $\{\Theta_k\}$ are independent identically distributed random vectors and each tree casts a unit vote for the most popular class at input x ."

Dua sumber keacakan yang digunakan untuk memastikan diversitas antar pohon:

- **Bootstrap Sampling (Bagging):** Setiap pohon ke- t dilatih pada subset data D_t yang dipilih dengan penggantian (with replacement) dari dataset asli. Rata-rata sekitar 63,2% sampel unik yang digunakan per pohon, sisanya merupakan out-of-bag (OOB) samples yang dapat digunakan untuk estimasi error internal tanpa perlu data validation terpisah.

- **Random Feature Selection:** Pada setiap split, hanya subset F fitur yang dipertimbangkan secara acak. Untuk klasifikasi, referensi [7] merekomendasikan $F = \lfloor \sqrt{p} \rfloor$ di mana p adalah total jumlah fitur. Ini memastikan dekorelasi antar pohon — jika satu fitur sangat dominan, ia tidak akan mendominasi setiap pohon.

Prediksi akhir Random Forest untuk klasifikasi ditentukan melalui majority voting dari semua T pohon:

$$\hat{y} = \underset{c}{\operatorname{argmax}} \sum_{t=1}^T \mathbb{1}[h(x; \Theta_t) = c] \quad (16)$$

Referensi [7] membuktikan melalui Law of Large Numbers bahwa random forests tidak mengalami overfitting seiring bertambahnya jumlah pohon. Generalization error konvergen ke batas stabil:

$$\begin{aligned} PE^* &= P_{\{X,Y\}}(P_{\Theta}(h(X,\Theta) = Y) - \max_{j \neq Y} P_{\Theta}(h(X,\Theta) = j) < 0) \end{aligned} \quad (17)$$

Referensi [7] juga menunjukkan melalui Theorem 2.3 bahwa upper bound untuk generalization error bergantung pada dua parameter kunci: strength (s) dari masing-masing pohon individual dan correlation (ρ) antar pohon:

$$PE^* \leq \bar{\rho} \cdot (1 - s^2) / s^2 \quad (18)$$

Implikasinya: forest yang baik harus memiliki pohon-pohon yang kuat secara individual (s tinggi) namun dekorelasi antar pohon tetap dijaga ($\bar{\rho}$ rendah). Dalam penelitian ini, Random Forest dengan `n_estimators = 100` dan `random_state = 42` digunakan sebagai model pembandingan (runner-up) terhadap Gradient Boosting.

G. Logistic Regression sebagai Model Baseline

Logistic Regression adalah model diskriminatif yang memodelkan probabilitas posterior kelas positif menggunakan fungsi sigmoid (logistik):

$$\begin{aligned} p(y=1 | x) &= \sigma(w^T x + b) \\ &= 1 / (1 + e^{\{-(w^T x + b)\}}) \end{aligned} \quad (19)$$

di mana w adalah vektor bobot dan b adalah bias. Model dilatih dengan memaksimalkan log-likelihood — yang ekuivalen dengan meminimumkan binary cross-entropy loss:

$$L(w,b) = -(1/n) \sum_{i=1}^n [y_i \log(p_i) + (1-y_i) \log(1-p_i)] \quad (20)$$

Dalam penelitian ini, Logistic Regression dengan `max_iter = 1000` dan `solver = 'lbfgs'` digunakan sebagai baseline model untuk mengukur apakah model yang lebih

kompleks (Gradient Boosting dan Random Forest) memberikan peningkatan performa yang bermakna dibandingkan pendekatan linear sederhana.

H. Market Impact Score sebagai Proxy Kesuksesan

Karena data pendapatan tidak tersedia secara publik, penelitian ini mendefinisikan **Market Impact Score (MIS)** sebagai metrik komposit yang merepresentasikan kesuksesan game dari empat dimensi yang saling melengkapi. Setiap komponen dinormalisasi terlebih dahulu menggunakan min-max normalization ke rentang [0, 1]:

$$\text{norm}(x) = (x - x_{\min}) / (x_{\max} - x_{\min}) \quad (21)$$

Kemudian, MIS dihitung sebagai rata-rata aritmetika dari keempat komponen yang telah dinormalisasi:

$$\text{MIS} = (\text{owners_norm} + \text{ccu_norm} + \text{rec_norm} + \text{ratio_norm}) / 4 \quad (22)$$

TABEL I. KOMPONEN MARKET IMPACT SCORE

Komponen	Variabel Sumber	Dimensi Kesuksesan	Justifikasi Bisnis
owners_norm	estimated_owners_mid	Market Reach (Jangkauan)	Game dengan lebih banyak pemilik memiliki dampak pasar lebih besar
ccu_norm	peak_ccu	Active Engagement (Keterlibatan)	CCU puncak mencerminkan kualitas retention pemain
rec_norm	recommendations	Community Support (Dukungan)	Rekomendasi aktif mencerminkan kepuasan mendalam (lebih dari sekadar review positif)
ratio_norm	positive_ratio	Reception Quality (Kualitas)	Korelasi tertinggi dengan

			keberhasilan jangka panjang (r=0,75 dengan MIS)
--	--	--	---

Keunggulan metrik komposit ini dibandingkan metrik tunggal adalah ketahanannya terhadap bias per-segmen. Game free-to-play (F2P) umumnya memiliki owners_norm sangat tinggi namun ratio_norm yang lebih rendah, sementara game berbayar premium berkualitas tinggi cenderung memiliki semua komponen yang seimbang. Pendekatan rata-rata memberikan representasi yang lebih holistik dan adil lintas model bisnis yang berbeda.

I. Metrik Evaluasi Model

Evaluasi model klasifikasi dalam konteks class imbalance memerlukan pemilihan metrik yang tepat. Penelitian ini menggunakan tiga metrik utama:

AUC-ROC (Area Under the Receiver Operating Characteristic Curve): Metrik utama yang mengukur kemampuan diskriminasi model secara keseluruhan di semua threshold klasifikasi. Dihitung sebagai luas di bawah kurva yang memplot True Positive Rate (Recall) terhadap False Positive Rate. AUC-ROC dipilih sebagai metrik utama karena robust terhadap class imbalance — tidak terpengaruh oleh dominasi kelas mayoritas.

$$\text{AUC} = \int_0^1 \text{TPR}(t) \, d(\text{FPR}(t)) \quad (23)$$

F1-Score untuk Kelas Sukses: Rata-rata harmonis dari Precision dan Recall khusus untuk kelas minoritas (sukses), memberikan gambaran yang seimbang tentang seberapa baik model mengidentifikasi game sukses:


$$\text{F1} = 2 \cdot (\text{Precision} \cdot \text{Recall}) / (\text{Precision} + \text{Recall}) \quad (24)$$

Silhouette Score untuk Clustering: Digunakan untuk menentukan K optimal dan mengevaluasi kualitas hasil clustering sesuai persamaan.

III. METODE PENELITIAN

A. Kerangka Penelitian (CRISP-DM)

Penelitian ini secara keseluruhan mengikuti framework CRISP-DM yang diimplementasikan secara iteratif. Dimulai dari Business Understanding untuk mendefinisikan tujuan bisnis berupa pembangunan DSS bagi pengembang indie, dilanjutkan ke Data Understanding melalui eksplorasi statistik dan visualisasi dataset Steam. Tahap Data Preparation mencakup feature engineering, pembentukan label kesuksesan, penanganan class imbalance dengan SMOTE, dan pembagian dataset. Tahap Modeling meliputi pelatihan tiga model klasifikasi dan K-Means Clustering. Evaluation dilakukan dengan metrik AUC-ROC, accuracy, F1-score, dan Silhouette Score. Terakhir, Deployment mengintegrasikan model ke dalam aplikasi Streamlit.



Gbr. 1. Diagram Alur Framework CRISP-DM yang Diterapkan dalam Penelitian.

B. Business Understanding

1) *Konteks Bisnis dan Motivasi Penelitian:* Platform Steam merupakan ekosistem distribusi game digital terbesar di dunia dengan lebih dari 50.000 judul game aktif dan ratusan game baru yang dirilis setiap bulannya. Berdasarkan data Steam Games Dataset yang digunakan dalam penelitian ini, hanya sekitar **8%** dari 124.146 game yang berhasil mencapai tingkat kesuksesan signifikan (tier Successful ke atas berdasarkan Market Impact Score). Fenomena ketimpangan ekstrem ini yang dikenal sebagai *long-tail distribution* menimbulkan pertanyaan bisnis yang kritis: *faktor-faktor apa saja yang membedakan segelintir game sukses dari mayoritas yang gagal?*

Kondisi ini menciptakan kebutuhan nyata dari sisi industri. Pengembang game indie, yang umumnya memiliki sumber daya terbatas (anggaran kecil, tim kecil, tidak ada dukungan publisher besar), tidak memiliki akses ke data historis yang memadai untuk membuat keputusan berbasis data sebelum meluncurkan produk mereka. Keputusan-keputusan kritis seperti penetapan harga, pemilihan genre, penentuan jumlah achievement, pemilihan platform, dan timing rilis selama ini banyak dibuat berdasarkan intuisi atau peniruan terhadap game populer yang mungkin tidak relevan dengan konteks mereka.

2) *Pernyataan Masalah (Problem Statement):* Berdasarkan analisis konteks bisnis di atas, masalah penelitian ini dapat dinyatakan sebagai berikut: *"Bagaimana membangun sistem prediksi berbasis data mining yang dapat membantu pengembang game indie mengevaluasi potensi kompetitif game sebelum diluncurkan, menggunakan data historis dari lebih dari 124 ribu game Steam?"*

Masalah ini diuraikan lebih lanjut ke dalam tiga sub-masalah spesifik:

Sub-masalah 1 (Prediksi): Dapatkah atribut pre-launch sebuah game (harga, genre, platform, achievement, timing rilis) digunakan untuk memprediksi apakah game tersebut akan sukses secara pasar dengan akurasi yang melampaui baseline naive classifier?

Sub-masalah 2 (Segmentasi): Apakah terdapat kelompok-kelompok game yang secara alami memiliki karakteristik

performa pasar yang homogen dan dapat diidentifikasi melalui clustering tanpa label sebelumnya?

Sub-masalah 3 (Implementasi): Bagaimana mengemas model machine learning yang dihasilkan ke dalam antarmuka yang dapat digunakan secara praktis oleh pengembang indie tanpa latar belakang data science?

3) Tujuan Bisnis (Business Goals):

TABEL II. PEMETAAN TUJUAN BISNIS KE TUJUAN DATA MINING

ID	Tujuan Bisnis	Tujuan Data Mining	Metode
BG-1	Membantu pengembang memprediksi potensi sukses game sebelum rilis	Klasifikasi biner: sukses vs. tidak sukses berdasarkan fitur pre-launch	Gradient Boosting, Random Forest, Logistic Regression
BG-2	Memberikan gambaran lanskap kompetitif pasar Steam kepada pengembang	Segmentasi game ke dalam arketipe pasar yang bermakna	K-Means Clustering (K=4)
BG-3	Mengidentifikasi faktor-faktor yang paling menentukan kesuksesan game	Analisis feature importance untuk mengekstrak insight bisnis actionable	Feature Importance (Gradient Boosting)
BG-4	Menyediakan alat DSS yang dapat digunakan pengembang secara mandiri	Deployment model ke aplikasi web interaktif real-time	Streamlit Web App

4) *Kriteria Keberhasilan (Success Criteria):* Kriteria keberhasilan penelitian ini didefinisikan pada dua level. Pada level **teknis**, model dianggap berhasil jika: (a) $AUC-ROC \geq 0,80$ pada data test yang tidak dimodifikasi — nilai ini dipilih karena secara umum dianggap sebagai ambang batas *good discrimination* dalam literatur machine learning; (b) Silhouette Score clustering $\geq 0,50$ yang menunjukkan struktur cluster yang bermakna; dan (c) model dapat menghasilkan prediksi dalam waktu < 2 detik pada antarmuka web untuk memastikan pengalaman pengguna yang baik.

Pada level **bisnis**, keberhasilan diukur dari: (a) kemampuan sistem memberikan rekomendasi yang berbeda dan spesifik per genre (bukan saran generik); (b) feature importance yang masuk akal secara domain knowledge industri game; dan (c) arketipe clustering yang memiliki

interpretasi bisnis yang jelas dan dapat dikomunikasikan kepada pengembang non-teknis.

5) Pemangku Kepentingan dan Pengguna Target (Stakeholder Analysis):

TABEL III. ANALISIS PEMANGKU KEPENTINGAN

Pemangku Kepentingan	Peran	Kebutuhan Utama	Output Sistem
Pengembang Indie	Pengguna Utama	Umpan balik cepat atas rancangan game sebelum investasi penuh dilakukan	Skor kompetitif, diagnostik fitur, rekomendasi genre-specific
Investor / Publisher Indie	Pengguna Sekunder	Due diligence berbasis data terhadap pipeline game yang akan didanai	Analisis arketipe pasar, perbandingan dengan benchmark industri
Tim Akademik (Kelompok 15)	Pengembang Sistem	Validasi metodologi CRISP-DM dan keakuratan model	Laporan teknis, evaluasi metrik model, dokumentasi kode
Dosen Pengampu	Evaluator	Penerapan framework data mining yang benar dan terdokumentasi	Laporan UAS lengkap, demo aplikasi, notebook Jupyter

6) Asumsi dan Batasan Penelitian:

Asumsi: (1) Market Impact Score yang dikonstruksi (rata-rata dari owners_norm, ccu_norm, rec_norm, positive_ratio) merupakan proxy kesuksesan yang valid meskipun tidak mencerminkan data pendapatan aktual; (2) Data Steam Games Dataset merepresentasikan distribusi populasi game Steam secara representatif; (3) Pola historis kesuksesan game masih relevan untuk diaplikasikan ke game yang akan dirilis di masa mendatang, walaupun dengan penyesuaian temporal melalui fitur release_year.

Batasan: (1) Dataset tidak mengandung data revenue/pendapatan aktual karena Valve Corporation tidak mempublikasikan data ini secara terbuka; (2) Faktor-faktor pasca rilis seperti update konten, strategi marketing,

kolaborasi dengan streamer/YouTuber, dan liputan media tidak dapat dimodelkan karena tidak tersedia pada saat prediksi dilakukan (pre-launch); (3) Model divalidasi hanya pada data Steam dan tidak dapat secara langsung digeneralisasi ke platform lain seperti Epic Games Store atau GOG.

C. Dataset

1) Sumber dan Karakteristik Data: Dataset yang digunakan adalah Steam Games Dataset yang dipublikasikan oleh FronkonGames di platform HuggingFace dengan lisensi CC BY 4.0. Dataset ini dikumpulkan melalui Steam Web API dan mencakup data game Steam dari tahun 1997 hingga 2026, meliputi metadata game, statistik review, data pemilik, informasi harga, genre, dukungan platform, serta metrik engagement pemain.

TABEL IV. KARAKTERISTIK DATASET STEAM GAMES

Karakteristik	Nilai	Keterangan
Total Records	124.146	Judul game unik di Steam
Total Kolom (Raw)	41 kolom	Sebelum preprocessing
Kolom yang Digunakan	18 kolom	Setelah seleksi fitur relevan
Fitur Model (setelah engineering)	24 fitur	Input ke model prediksi
Missing Values	0 (0%)	Dataset lengkap, tanpa nilai hilang
Rentang Tahun	1997 – 2026	Tahun rilis game dalam dataset
Lisensi	CC BY 4.0	Creative Commons Attribution 4.0
Sumber Platform	HuggingFace / Kaggle	FronkonGames/steam-games-dataset

Dataset yang digunakan dalam penelitian ini memiliki cakupan yang sangat luas karena mencakup lebih dari 124 ribu judul game yang dirilis pada platform Steam selama hampir tiga dekade. Jumlah data yang besar ini memberikan keuntungan dalam proses pemodelan karena mampu merepresentasikan berbagai jenis game, model bisnis, serta karakteristik pasar yang beragam. Selain itu, tidak ditemukannya missing value menunjukkan bahwa kualitas data relatif baik sehingga proses preprocessing dapat difokuskan pada seleksi fitur dan rekayasa fitur tanpa perlu melakukan imputasi data.

2) Statistik Deskriptif Fitur Utama: Tabel berikut merangkum statistik deskriptif dari fitur-fitur numerik utama yang digunakan dalam analisis. Sebagian besar fitur memiliki distribusi yang sangat tidak merata (right-skewed), di mana nilai rata-rata jauh lebih tinggi dibandingkan median. Ini mengindikasikan keberadaan sejumlah kecil game dengan performa yang sangat dominan di tengah mayoritas game yang memiliki metrik rendah.

TABEL V. STATISTIK DESKRIPTIF FITUR NUMERIK UTAMA

Fitur	Mean	Std Dev	Min	Median	Max
Price (USD)	4,79	12,51	0,00	2,39	999,98
Achievements	18,01	140,63	0	2	9.821
Positive Reviews	1.032,10	27.917,76	0	5	7.642.084
Negative Reviews	167,12	5.341,35	0	1	1.173.003
Peak CCU	53,92	3.706,33	0	0	1.013.936
Avg Playtime (mnt)	205,46	11.148,14	0	0	3.429.544
Recommendations	950,12	21.743,39	0	0	4.830.455

D. Data Understanding (Exploratory Data Analysis)

Tahap EDA dilakukan untuk memahami distribusi, pola, dan hubungan antar variabel sebelum pemodelan. Beberapa temuan kunci dari tahap ini adalah:

3) *Distribusi Harga*: Distribusi harga game di Steam sangat condong ke kiri. Lebih dari 97% game dijual dengan harga di bawah \$20, dengan median harga hanya \$2,39. Sebanyak 26.412 game (21,3%) merupakan game free-to-play. Hal ini mencerminkan preferensi pasar yang kuat terhadap titik harga yang terjangkau — sebuah faktor yang harus dipertimbangkan secara serius oleh pengembang indie dalam strategi penetapan harga produk mereka.

4) *Domikasi Genre Indie*: Genre Indie merupakan genre yang paling dominan dengan lebih dari 80.000 game, diikuti Casual (~51.000), Action (~47.000), dan Adventure (~46.000). Kondisi ini mencerminkan tingginya partisipasi pengembang indie dalam ekosistem Steam dan memperkuat urgensi penelitian ini. Genre RPG memiliki rata-rata market impact score tertinggi di antara genre mainstream, mengindikasikan bahwa pemain RPG memiliki engagement dan willingness-to-pay yang lebih tinggi.

5) *Distribusi Platform*: Windows mendukung hampir seluruh game (>99%), sementara Mac dan Linux masing-masing hanya didukung sekitar 18% dan 13% game. Ini mencerminkan dominasi platform Windows dalam ekosistem gaming PC dan menunjukkan bahwa dukungan multi-platform merupakan differentiator yang relatif langka namun berpotensi meningkatkan jangkauan pasar.

6) *Korelasi Fitur*: Positive reviews, negative reviews, peak CCU, recommendations, dan estimated owners memiliki korelasi sangat tinggi satu sama lain ($r > 0,6$), mengindikasikan bahwa semua metrik ini mencerminkan dimensi popularitas yang sama. Positive ratio memiliki korelasi tertinggi dengan market impact score ($r = 0,75$), mengindikasikan bahwa kualitas penerimaan adalah prediktor terkuat kesuksesan game. Price memiliki korelasi yang sangat lemah dengan semua variabel lain ($r < 0,1$).

7) *Distribusi Market Impact Score*: Distribusi sangat miring ke kanan (right-skewed), mengonfirmasi long-tail distribution. Mayoritas game memiliki skor mendekati 0,

sementara hanya segelintir game (seperti Counter-Strike 2, Dota 2, PUBG) yang mencapai skor mendekati 1,0.

E. Data Preparation

1) *Feature Engineering*: Beberapa fitur baru direkayasa dari data mentah untuk meningkatkan kemampuan prediktif dan interpretatif model. Proses ini bertujuan menghasilkan representasi data yang lebih informatif dibandingkan fitur mentah yang tersedia pada dataset awal.

TABEL VI. FITUR-FITUR YANG DIREKAYASA (FEATURE ENGINEERING)

Fitur Baru	Formula / Sumber	Keterangan
positive_ratio	positive / (positive + negative)	Rasio ulasan positif (0–1)
engagement_score	$\log(\text{peak_ccu} + 1) \times \text{playtime_norm}$	Skor keterlibatan aktif pemain
market_impact_score	Rata-rata: owners_norm, ccu_norm, rec_norm, positive_ratio	Target label utama (0–1)
platform_count	windows + mac + linux (0–3)	Jumlah platform yang didukung
is_free	1 if price == 0, else 0	Flag game gratis (biner)
release_year, release_month	Ekstrak dari release date	Komponen waktu rilis
genre_[X]	One-hot encoding dari kolom genres	14 fitur genre biner
combo_[X]_[Y]	Kombinasi genre yang sering muncul bersamaan	3 fitur kombinasi genre populer
success_label	Binning market_impact_score ke 5 tier	Label kategori kesuksesan

2) *Definisi Label Kesuksesan*: Label kesuksesan (success_label) didefinisikan ke dalam lima tier berdasarkan distribusi market_impact_score. Distribusi label menunjukkan bahwa mayoritas game berada pada kategori Failure dan Moderate, sedangkan kategori Hit dan Generational Hit hanya mencakup sebagian kecil dari keseluruhan populasi. Ketimpangan distribusi ini mencerminkan kondisi nyata industri game digital.

TABEL VII. DISTRIBUSI LABEL KESUKSESAN (SUCCESS TIER)

Tier	Rang e Score	Jumla h Game	Persentas e	Deskripsi
Failure	< 0,20	55.689	44,86%	Underpromising launch
Moderate	0,20 – 0,40	58.554	47,17%	Below-average performance
Successful	0,40 – 0,60	8.479	6,83%	Solid commercial release
Hit	0,60 – 0,80	1.366	1,10%	Strong market performance

Generational Hit	$\geq 0,80$	58	0,05%	Top-tier iconic status
------------------	-------------	----	-------	------------------------

3) *Penanganan Class Imbalance dengan SMOTE*: Untuk model prediksi biner (sukses/tidak sukses), dataset menunjukkan ketidakseimbangan yang sangat signifikan. Dari 99.316 data pelatihan, hanya 7.922 (7,98%) yang termasuk kelas sukses. Jika model dilatih menggunakan distribusi data asli, model cenderung memprediksi kelas mayoritas karena jumlahnya jauh lebih besar. SMOTE diterapkan eksklusif pada data pelatihan untuk menghindari data leakage.

TABEL VIII. DISTRIBUSI KELAS SEBELUM DAN SETELAH SMOTE

Kondisi		Kelas 0 (Tidak Sukses)	Kelas 1 (Sukses)
Sebelum SMOTE (Train)		91.394 (92,02%)	7.922 (7,98%)
Setelah SMOTE (Train)		91.394 (50,00%)	91.394 (50,00%)

4) *Pembagian Dataset*: Dataset dibagi dengan rasio 80:20 menggunakan stratified sampling untuk memastikan proporsi kelas yang representatif pada data pelatihan dan pengujian. Data pelatihan: 99.316 records (80%), setelah SMOTE menjadi 182.788 records.

F. Modeling

1) *Model Prediksi (Supervised Learning)*: Tiga algoritma klasifikasi dipilih untuk dibandingkan, mewakili pendekatan yang berbeda dalam machine learning. Logistic Regression digunakan sebagai model baseline. Random Forest dipilih karena mampu menangani hubungan non-linear serta relatif tahan terhadap noise dan overfitting. Gradient Boosting digunakan sebagai model utama karena dikenal memiliki performa sangat baik pada data tabular. Parameter yang digunakan:

- Gradient Boosting Classifier: $n_estimators=100$, $learning_rate=0.1$, $max_depth=3$
- Random Forest Classifier: $n_estimators=100$, $random_state=42$, $n_jobs=-1$
- Logistic Regression: $max_iter=1000$, $solver=lbfgs$, $random_state=42$


Fitur input model berjumlah 24 atribut: price, is_free, achievements, platform_count, release_year, release_month, genre_count, dan 17 fitur genre/kombinasi genre hasil one-hot encoding.

2) *Model Clustering (Unsupervised Learning)*: K-Means Clustering diterapkan untuk segmentasi pasar menggunakan empat fitur utama: price, estimated_owners_mid, engagement_score, dan positive_ratio. Fitur-fitur ini dinormalisasi menggunakan StandardScaler sebelum clustering karena K-Means menggunakan jarak Euclidean yang sensitif terhadap perbedaan skala. Penentuan K optimal dilakukan dengan Elbow Method dan Silhouette Score pada rentang K=2 hingga K=6.

IV. HASIL DAN PEMBAHASAN


A. Hasil Exploratory Data Analysis (EDA)

1) *Distribusi Market Impact Score*: Distribusi market_impact_score menunjukkan pola right-skewed yang sangat ekstrem. Mayoritas besar game (lebih dari 80%) memiliki skor mendekati 0, sementara hanya segelintir game yang berhasil mencapai skor tinggi. Pola ini mengonfirmasi hipotesis long-tail distribution dalam industri game indie: sangat banyak game bersaing untuk mendapatkan perhatian pasar yang sangat terbatas, dan hanya sebagian kecil yang berhasil menonjol.



Gbr. 2. Distribusi Market Impact Score pada Dataset Steam ($n=124.146$).


2) *Distribusi Success Tier*: Hasil pembagian market_impact_score ke dalam lima tier kesuksesan menunjukkan dominasi kelas Moderate (47,17%) dan Failure (44,86%), yang secara bersama-sama mencakup lebih dari 92% dari seluruh game dalam dataset. Hanya 8.479 game (6,83%) yang berhasil mencapai tier Successful, 1.366 game (1,10%) mencapai tier Hit, dan hanya 58 game (0,05%) yang berhasil menjadi Generational Hit. Distribusi ini secara langsung mencerminkan realita persaingan di ekosistem game indie Steam.



Gbr. 3. Distribusi Label Kesuksesan (Success Tier) Seluruh Dataset.


3) *Distribusi Harga dan Model Bisnis*: Analisis distribusi harga mengungkapkan bahwa pasar Steam sangat

didominasi oleh game dengan harga rendah. Sebanyak 26.412 game (21,3%) merupakan game free-to-play, sementara segmen harga \$0,01–\$5 merupakan yang terbesar dengan 66.079 game. Ini mencerminkan preferensi pasar yang kuat terhadap titik harga yang terjangkau, sebuah faktor yang harus dipertimbangkan secara serius oleh pengembang indie dalam strategi penetapan harga.




Gbr. 4. Distribusi Harga Game dan Perbandingan Free vs Paid.

4) *Distribusi Platform dan Genre*: Dari sisi dukungan platform, Windows mendominasi secara mutlak (>99%), sementara dukungan multi-platform hanya mencakup sekitar 18% dari total game. Dari sisi genre, Indie merupakan yang paling dominan (>80.000 game), diikuti Casual, Action, dan Adventure. Analisis market impact score per genre menunjukkan bahwa RPG, Strategy, dan Simulation memiliki rata-rata skor tertinggi, mengindikasikan bahwa game dengan konten yang lebih dalam cenderung memiliki engagement yang lebih kuat.




Gbr. 5. Platform Support Distribution.



Gbr. 6. Market Impact Score per Genre.

5) *Analisis Korelasi Fitur*: Feature correlation heatmap mengungkapkan beberapa pola penting. Pertama, positive reviews, negative reviews, peak CCU, dan recommendations memiliki korelasi sangat tinggi ($r > 0,6$), menunjukkan bahwa keempatnya mengukur dimensi popularitas yang sama. Kedua, positive_ratio memiliki korelasi tertinggi dengan market_impact_score ($r = 0,75$), mengindikasikan bahwa kualitas penerimaan adalah prediktor terkuat. Ketiga, price memiliki korelasi yang sangat lemah dengan semua variabel lain ($r < 0,1$), menunjukkan bahwa harga bukan determinan tunggal kesuksesan.




Gbr. 7. Feature Correlation Heatmap Fitur-Fitur Numerik Dataset.

B. Hasil Clustering (K-Means)

1) *Penentuan K Optimal*: Berdasarkan hasil Elbow Method dan Silhouette Score yang dijalankan pada rentang K=2 hingga K=6, nilai K=4 dipilih sebagai jumlah cluster optimal. Silhouette Score mencapai nilai maksimum pada K=4 (0,6632), yang mengindikasikan bahwa pada K=4, data point dalam setiap cluster memiliki kesamaan internal yang tinggi sekaligus perbedaan yang jelas antar cluster. Pada K=5 dan K=6, Silhouette Score menurun, menandakan bahwa penambahan cluster justru menurunkan kualitas segmentasi.

TABEL IX. HASIL ELBOW METHOD DAN SILHOUETTE SCORE (K=2 HINGGA K=6)

K	Inertia	Silhouette Score	Keterangan
2	1.046	0,6124	Terlalu sedikit cluster
3	679	0,6480	Masih ada perbaikan signifikan
4	364	0,6632	OPTIMAL — dipilih
5	216	0,6316	Silhouette Score menurun
6	176	0,5918	Cluster terlalu banyak



Gbr. 8. Elbow Method (Inertia) dan Silhouette Score untuk Penentuan K Optimal.

2) *Profil Empat Arketipe Pasar*: Hasil K-Means Clustering dengan K=4 mengidentifikasi empat arketipe pasar yang memiliki karakteristik yang jelas dan bermakna secara bisnis:

TABEL X. PROFIL EMPAT ARKETIPE PASAR STEAM (K-MEANS, K=4)


Arketipe	N Game	Porsi	Med . Price	Engagement	Success Rate
Market Leaders	12.102	9,75%	\$4,99	601,65	76%
Casual Hits	61.371	49,44%	\$2,49	0,00	0%
Meme/Viral Games	26.827	21,61%	\$2,99	0,00	20%
Abandoned Projects	22.908	18,45%	\$0,00	0,00	0%

Market Leaders (n=12.102, 9,75%): Merepresentasikan game-game terbaik di Steam. Ditandai dengan engagement score tertinggi (rata-rata 601,65), jumlah pemilik signifikan (~75.000), positive ratio tinggi (0,82), dan success rate 76%. Game dalam cluster ini umumnya memiliki release year lebih awal (rata-rata 2019) dan jumlah achievement yang banyak (41,70). Contoh game dalam kategori ini termasuk judul ikonik seperti Counter-Strike 2, Dota 2, Stardew Valley, dan Baldur's Gate 3.


Casual Hits (n=61.371, 49,44%): Cluster terbesar yang mencakup hampir separuh dari seluruh game di Steam. Game-game ini memiliki harga rendah (\$2,49), engagement minimal, namun tetap memiliki basis pemilik kecil (~10.000). Cluster ini mewakili 'tulang punggung' ekosistem indie Steam — game-game yang berhasil dijual namun tidak mencapai traction yang signifikan di komunitas pemain.

Meme/Viral Games (n=26.827, 21,61%): Cluster yang mencakup game-game yang mendapatkan perhatian pasar melalui mekanisme viral atau komunitas niche. Success rate 20% yang lebih tinggi dari Casual Hits, meskipun engagement score rata-ratanya rendah, mengindikasikan bahwa sebagian game dalam cluster ini mendapat momen viral yang signifikan namun tidak konsisten secara keseluruhan.

Abandoned Projects (n=22.908, 18,45%): Cluster yang merepresentasikan game-game tanpa traction pasar sama sekali. Ditandai dengan harga \$0 (kemungkinan belum dirilis penuh, early access terbengkalai, atau telah dihapus dari penjualan), engagement nol, dan tidak ada pemilik yang tercatat. Cluster ini menjadi peringatan nyata tentang risiko kegagalan di pasar Steam.



Gbr. 9. Steam Market Intelligence — Ringkasan Empat Arketipe Pasar.



Gbr. 10. 3D Market Ecosystem: Scatter Plot Cluster (Scale vs Reception vs Hype).



Gbr. 11. Distribusi Arketipe Pasar Steam (Donut Chart).

C. Hasil Model Prediksi

1) *Perbandingan Performa Model*: Tiga model klasifikasi dievaluasi menggunakan data test yang tidak dimodifikasi (24.830 records). Metrik utama yang digunakan adalah AUC-ROC, karena lebih robust terhadap class imbalance dibandingkan accuracy semata. AUC-ROC yang tinggi mengindikasikan bahwa model mampu membedakan antara game sukses dan tidak sukses secara konsisten di berbagai threshold klasifikasi.

TABEL XI. PERBANDINGAN PERFORMA TIGA MODEL KLASIFIKASI

Model	Accuracy	AUC-ROC	F1 (Sukses)	Status
Gradient Boosting	91,52%	0,8732	0,41	TERBAIK
Random Forest	92,65%	0,8688	0,43	Runner-up

Logistic Regression	68,89%	0,7654	0,31	Baseline
---------------------	--------	--------	------	----------


Gradient Boosting dipilih sebagai model terbaik berdasarkan AUC-ROC tertinggi (0,8732). Meskipun Random Forest memiliki accuracy yang sedikit lebih tinggi (92,65%), perbedaan ini disebabkan oleh dominasi kelas mayoritas (Not Success). AUC-ROC yang lebih tinggi pada Gradient Boosting mencerminkan kemampuan yang lebih baik dalam membedakan game sukses dari yang tidak sukses secara keseluruhan.

2) *Evaluasi Detail Gradient Boosting*: Classification report berikut menunjukkan detail performa model pada setiap kelas.

TABEL XII. CLASSIFICATION REPORT GRADIENT BOOSTING PADA DATA TEST

Kelas	Precision	Recall	F1-Score	Support
Not Success	0,95	0,96	0,95	22.849
Success	0,46	0,38	0,41	1.981
Macro Average	0,70	0,67	0,68	24.830
Weighted Average	0,91	0,92	0,91	24.830

Confusion matrix menunjukkan bahwa model sangat baik dalam mengidentifikasi game yang tidak sukses (TN=21.979, precision=0,95), namun lebih moderat dalam mengidentifikasi game sukses (TP=746, precision=0,46). Hal ini disebabkan oleh dua faktor utama: (1) class imbalance yang masih ada pada data test, dan (2) keterbatasan inheren dari launch-day features — kesuksesan game juga sangat dipengaruhi oleh faktor pasca-rilis yang tidak tersedia dalam dataset.



Gbr. 12. Confusion Matrix dan ROC Curve Perbandingan Tiga Model.


3) *Analisis Feature Importance*: Feature importance dari model Gradient Boosting mengungkapkan kontributor utama dalam prediksi kesuksesan game:

TABEL XIII. TOP 10 FEATURE IMPORTANCE MODEL GRADIENT BOOSTING

Rank	Fitur	Importance	Interpretasi
1	achievements	~0,25	Indikator kedalaman dan kekayaan konten game
2	release_year	~0,20	Tren pasar Steam berubah signifikan setiap tahun
3	genre_Casual	~0,13	Genre Casual memiliki pasar yang sangat besar

4	genre_Indie	~0,08	Label Indie mempengaruhi visibilitas Steam
5	price	~0,06	Penetapan harga sangat kritis untuk penerimaan
6	genre_Adventure	~0,06	Genre dengan basis pemain yang loyal dan aktif
7	genre_Simulation	~0,05	Genre dengan engagement dan playtime tinggi
8	genre_Action	~0,05	Genre kompetitif dengan basis pasar besar
9	genre_RPG	~0,05	Dedikasi dan willingness to pay tertinggi
10	genre_Strategy	~0,04	Komunitas niche yang sangat terlibat

Temuan paling signifikan adalah dominasi fitur achievements sebagai prediktor terpenting (~0,25). Ini mengindikasikan bahwa sistem achievement yang kaya bukan sekadar fitur tambahan, melainkan sinyal kuat tentang kedalaman konten dan komitmen pengembang terhadap kualitas game. Release year sebagai prediktor kedua (~0,20) mencerminkan perubahan dinamika pasar Steam dari tahun ke tahun, di mana tingkat kompetisi, ekspektasi pemain, dan algoritma rekomendasi Steam terus berevolusi.



Gbr. 13. Top 10 Feature Importances Gradient Boosting (Bar Chart Horizontal).

D. Pembahasan Terintegrasi

1) *Insight 1 — Achievement sebagai Sinyal Kualitas:* Dominasi achievements sebagai fitur terpenting dalam prediksi menunjukkan bahwa investasi dalam sistem achievement yang bermakna merupakan salah satu strategi paling efektif yang dapat dilakukan pengembang indie. Achievement tidak hanya meningkatkan engagement langsung, tetapi juga menjadi sinyal kepada algoritma Steam tentang kedalaman dan kualitas game, serta mendorong pemain untuk terus bermain lebih lama.

2) *Insight 2 — Strategi Harga Berbasis Genre adalah Kunci:* Analisis median harga per genre dari EDA menunjukkan variasi yang signifikan: RPG (\$3,74), Strategy (\$2,99), dan Action (\$2,99) dapat dijual lebih mahal dibandingkan Casual (\$1,99). Penetapan harga yang tidak mempertimbangkan ekspektasi genre dapat berdampak negatif pada konversi wishlist ke pembelian. Pengembang perlu memposisikan harga sesuai dengan ekspektasi komunitas genre yang dituju.

3) *Insight 3 — Timing Rilis Berpengaruh Signifikan:* Bulan-bulan terbaik untuk rilis game di Steam berdasarkan data historis adalah Q4 (Oktober–Desember, bertepatan dengan holiday season dan Steam Winter Sale) dan awal tahun (Maret–April). Menghindari periode di mana game AAA besar mendominasi perhatian media juga merupakan strategi yang bijak bagi pengembang indie yang memiliki anggaran marketing terbatas.

4) *Insight 4 — DSS, Bukan Prediksi Deterministik:* Precision yang relatif rendah untuk kelas sukses (0,46) mengonfirmasi bahwa sistem ini paling tepat diposisikan sebagai Decision Support System yang membantu pengambilan keputusan berbasis data, bukan sebagai oracle yang menjamin kesuksesan. Faktor-faktor pasca-rilis seperti kualitas marketing, update konten, dan reaksi komunitas memiliki peran yang tidak kalah penting namun tidak dapat dimodelkan dari data pre-launch.


V. IMPLEMENTASI SISTEM

A. Arsitektur Sistem


Steam Game Success Analyzer diimplementasikan sebagai aplikasi web multi-halaman berbasis Streamlit versi 1.57.0 yang mengintegrasikan model machine learning yang telah dilatih (Gradient Boosting + K-Means) dengan antarmuka pengguna yang interaktif. Struktur proyek mengikuti konvensi UAS_DataMining_Kelompok15 dengan direktori data/, notebook/, model/, dan app/ yang berisi modul home.py, dataset.py, prediction.py, visualization.py, dan about.py.

B. Deskripsi Halaman Aplikasi

1) *Halaman Home:* Halaman beranda menampilkan ringkasan komprehensif proyek dalam format yang menarik secara visual. Empat metric card di bagian atas menampilkan statistik kunci secara real-time: total games (124.146), model AUC (87,32%), silhouette score (0,6632), dan features used (14). Di bawahnya terdapat visualisasi pipeline CRISP-DM yang menjelaskan enam tahap proses yang dilakukan, diikuti oleh Success Tier System yang mendefinisikan lima kategori kesuksesan beserta range score-nya. Bagian bawah menampilkan identitas tim pengembang dan tombol CTA (Call to Action) untuk menuju halaman Prediction.




Gbr. 14. Halaman Home — Overview Proyek dan Pipeline CRISP-DM.

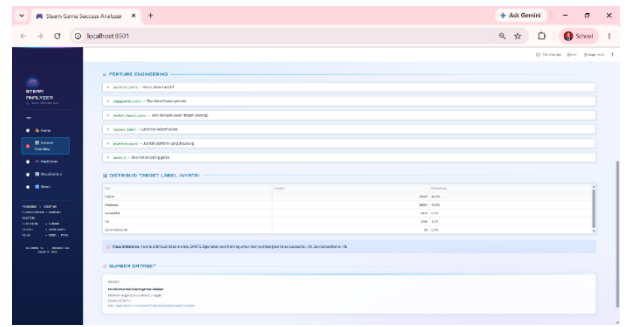


Gbr. 15. Halaman Home — Success Tier System dan Identitas Tim Pengembang.

2) **Halaman Dataset Overview:** Halaman ini menyajikan eksplorasi dataset secara lengkap dan transparan. Empat info card menampilkan statistik utama dataset: total records (124.146), fitur/kolom (41), rentang tahun (1997–2026), dan sumber data (Kaggle/HuggingFace). Bagian "Preview Data Nyata" menampilkan tabel interaktif dari data aktual yang digunakan. Bagian Feature Engineering menjelaskan fitur-fitur yang direkayasa. Distribusi target label ditampilkan dalam format tabel dengan penjelasan mengenai penanganan class imbalance menggunakan SMOTE. Sumber dataset beserta URL resmi juga dicantumkan secara transparan.




Gbr. 16. Dataset Overview — Informasi Dataset, Preview Data, dan Feature Engineering.



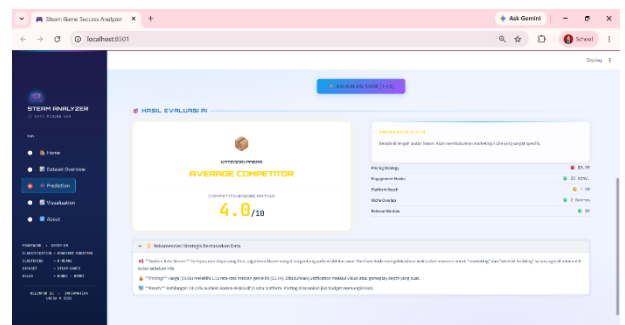
Gbr. 17. Dataset Overview — Distribusi Target Label dan Sumber Dataset.

3) **Halaman Prediction (Game Strategy Advisor – DSS):** Halaman inti dari sistem yang berfungsi sebagai Decision Support System. Pengguna memasukkan parameter rancangan game melalui form yang intuitif: toggle Free to Play, input harga (USD), jumlah achievement, dukungan platform (Windows/macOS/Linux), bulan dan tahun rilis target, serta genre utama (multi-select). Panel Input Summary di sebelah kanan menampilkan ringkasan parameter secara real-time beserta benchmark harga median per genre dari data EDA.

Setelah menekan tombol "KALKULASI SKOR (1–10)", sistem memproses input melalui model Gradient Boosting yang telah dimuat dari file .pkl. Output mencakup: (1) Competitiveness Rating berupa skor numerik 1–10, (2) kategori pasar, (3) panel Diagnostik Fitur yang membandingkan setiap parameter dengan benchmark data Steam, dan (4) Rekomendasi Strategis berbasis data.



Gbr. 18. Halaman Prediction — Form Input Parameter Game dan Input Summary.

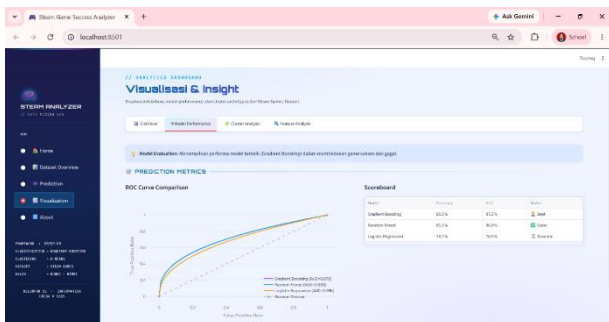


Gbr. 19. Prediction — Hasil Evaluasi Kalkulasi Skor dan Rekomendasi Strategis.

4) *Halaman Visualization*: Halaman ini menampilkan visualisasi interaktif yang diorganisasi dalam empat tab: (a) Tab Distribusi — bar chart distribusi Success Tier, distribusi harga game berdasarkan segmen harga, dan pie chart dukungan platform; (b) Tab Model Performance — ROC Curve Comparison tiga model dan scoreboard perbandingan performa; (c) Tab Cluster Analysis — 3D scatter plot Market Ecosystem, Elbow Method + Silhouette Score chart, dan donut chart distribusi arketipe; (d) Tab Feature Analysis — feature importance dan analisis korelasi fitur.



Gbr. 20. Visualization Tab Distribusi — Success Tier, Harga, dan Platform.



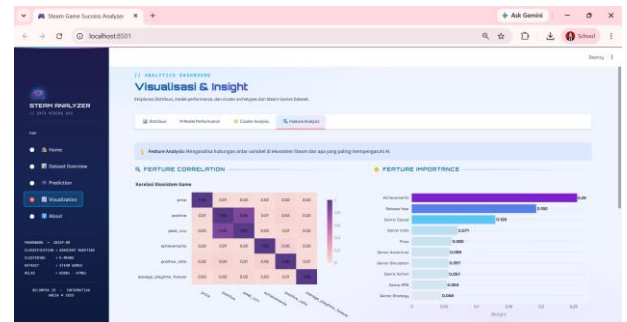
Gbr. 21. Visualization Tab Model Performance — ROC Curve dan Scoreboard.



Gbr. 22. Visualization Tab Cluster Analysis — 3D Market Ecosystem.

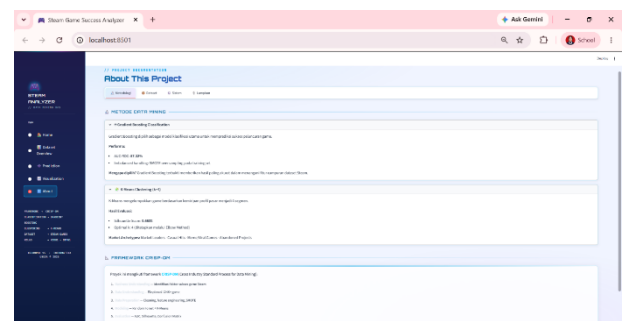


Gbr. 23. Visualization Tab Cluster Analysis — Elbow Method dan Distribusi Arketipe.




Gbr. 24. Visualization Tab Feature Analysis — Feature Correlation dan Feature Importance.

5) *Halaman About*: Halaman dokumentasi proyek terbagi dalam empat tab: Tab Metodologi (penjelasan Gradient Boosting Classification dan K-Means Clustering beserta performa dan alasan pemilihan, serta framework CRISP-DM), Tab Dataset (detail dataset: nama, sumber, jumlah record, lisensi), Tab Sistem (tech stack yang digunakan), dan Tab Lampiran (tautan ke dataset, source code notebook, aplikasi live demo, video presentasi, repository project, dan laporan PDF).



Gbr. 25. Halaman About Tab Metodologi — Metode Data Mining dan Framework CRISP-DM.



Gbr. 26. Halaman About Tab Dataset, Sistem (Tech Stack), dan Lampiran.

C. Teknologi yang Digunakan

TABEL XIV. TECH STACK SISTEM STEAM GAME SUCCESS ANALYZER

Komponen	Teknologi / Versi	Fungsi dalam Sistem
Bahasa Pemrograman	Python 3.11	Pengembangan seluruh pipeline analisis dan aplikasi
Web Framework	Streamlit 1.57.0	Antarmuka pengguna web interaktif multi-halaman
Machine Learning	scikit-learn	Gradient Boosting, Random Forest, K-Means, SMOTE
Imbalanced Learning	imbalanced-learn	SMOTE oversampling untuk class imbalance
Data Processing	Pandas / NumPy	Manipulasi data dan feature engineering
Visualisasi Interaktif	Plotly	Chart interaktif (3D scatter, ROC curve, bar chart)
Visualisasi Statis	Matplotlib / Seaborn	Grafik analisis dan EDA di notebook
Model Persistence	joblib	Serialisasi dan loading model .pkl
Dataset Source	HuggingFace datasets	Pengunduhan Steam Games Dataset (FronkonGames)
Development Environment	Jupyter Notebook	Eksplorasi data dan pengembangan model

VI. KESIMPULAN

Penelitian ini berhasil mengembangkan sistem analisis kesuksesan game Steam menggunakan kombinasi metode Gradient Boosting dan K-Means Clustering berdasarkan framework CRISP-DM. Beberapa kesimpulan utama yang dapat ditarik adalah sebagai berikut.

Pertama, model Gradient Boosting memberikan performa terbaik dalam memprediksi potensi kesuksesan game dengan nilai AUC-ROC sebesar 0,8732, mengungguli Random Forest (0,8688) dan Logistic Regression (0,7654). Fitur paling berpengaruh dalam prediksi adalah jumlah achievement (~0,25), tahun rilis (~0,20), dan genre Casual (~0,13). Temuan ini mengindikasikan bahwa kedalaman

konten game (achievement), pemahaman tren pasar terkini (tahun rilis), dan pemilihan genre yang tepat merupakan faktor-faktor kunci yang menentukan potensi kesuksesan sebuah game di platform Steam.

Kedua, proses K-Means Clustering menghasilkan empat arketipe pasar yang memiliki karakteristik jelas dan bermakna secara bisnis: Market Leaders (9,75%, success rate 76%), Casual Hits (49,44%), Meme/Viral Games (21,61%, success rate 20%), dan Abandoned Projects (18,45%). Segmentasi ini memberikan gambaran komprehensif tentang lanskap kompetitif platform Steam dan membantu pengembang indie memahami posisi produk mereka relatif terhadap game-game lain di pasar.

Ketiga, seluruh model berhasil diimplementasikan ke dalam aplikasi web berbasis Streamlit yang berfungsi sebagai Decision Support System bagi pengembang game indie. Sistem yang dikembangkan mampu memberikan prediksi kompetitif (skor 1–10), analisis diagnostik fitur, segmentasi pasar, visualisasi data interaktif, dan rekomendasi strategis berbasis data historis secara real-time melalui lima modul fungsional yang terintegrasi.

Sebagai saran untuk penelitian selanjutnya, disarankan untuk mengintegrasikan data pasca-rilis (update konten, strategi marketing, ulasan pengguna secara berkala) guna meningkatkan akurasi prediksi. Selain itu, pengembangan model time-series untuk menganalisis perubahan tren pasar Steam dari waktu ke waktu, serta eksplorasi teknik deep learning seperti neural network untuk menangkap pola yang lebih kompleks, dapat menjadi arah pengembangan yang menjanjikan.

UCAPAN TERIMA KASIH

Penulis mengucapkan terima kasih yang sebesar-besarnya kepada Ibu Wiyli Yustanti, S.Si., M.Kom. selaku dosen pengampu Mata Kuliah Data Mining KDD01-DTMG1, Program Studi Sistem Informasi, Fakultas Teknik, Universitas Negeri Surabaya, atas segala bimbingan, arahan, dan dukungan yang diberikan selama proses pengerjaan proyek akhir semester ini. Penulis juga mengucapkan terima kasih kepada FronkonGames atas penyediaan Steam Games Dataset dengan lisensi terbuka CC BY 4.0 yang menjadi fondasi dari penelitian ini.

REFERENSI

- [1] U. Fayyad, G. Piatetsky-shapiro, and P. Smyth, "From Data Mining to Knowledge Discovery in," pp. 37–54, 1996.
- [2] G. Lemaître, F. Nogueira, W. S. West, O. Mv, and C. K. Aridas, "Imbalanced-learn : A Python Toolbox to Tackle the Curse of Imbalanced Datasets in Machine Learning," vol. 18, pp. 1–5, 2017.
- [3] C. Pete *et al.*, "Step-by-step data mining guide".
- [4] J. Friedman, "1999 REITZ LECTURE," vol. 29, no. 5, pp. 1189–1232, 2001.
- [5] J. Macqueen, "SOME METHODS FOR CLASSIFICATION AND ANALYSIS OF MULTIVARIATE OBSERVATIONS," vol. 233, no.

233, pp. 281–297.

- [6] N. V Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, “SMOTE : Synthetic Minority Over-sampling Technique,” vol. 16, pp. 321–357, 2002.
- [7] L. E. O. Breiman, “Random Forests,” pp. 5–32, 2001.

LAMPIRAN

- 1) [Dataset](#)
- 2) [Google Colab](#)
- 3) [Video Presentasi](#)
- 4) [Repository Github](#)